Математическая статистика. ДЗ 13.

ПРОХОРОВ ЮРИЙ, 776

Задача 1

Пусть $\mathbf{X} = (X_1, \dots, X_n)$ — простая выборка из распределения с плотностью $f_{\theta}(x)$. Построить оптимальную оценку параметра θ , если

(a)
$$f_{\theta}(x) = \begin{cases} e^{-(x-\theta)} & , & x \ge \theta \\ 0 & , & x < \theta \end{cases}$$

(b)
$$f_{\theta}(x) = \begin{cases} \frac{1}{2\theta} e^{-\sqrt{x/\theta}} &, x \ge 0\\ 0 &, x < 0 \end{cases}$$

Решение:

- (a) Данная модель не является регулярной, поэтому будем строить эффективную оценку следующим алгоритмом:
 - 1. Найдем полную достаточную статистику $T(\mathbf{X})$.
 - 2. Найдем какую-нибудь простую несмещенную оценку $\widehat{\theta}_1(\mathbf{X})$.
 - 3. Согласно теореме Рао-Блеквелла-Колмогорова, построим оптимальную оценку

$$\widehat{\theta}(\mathbf{X}) = \mathbb{E}[\widehat{\theta}_1(\mathbf{X}) \mid T(\mathbf{X})]$$

Будем действовать по этому алгоритму.

1. Функция правдоподобия выборки:

$$L(\mathbf{X} \mid \theta) = \prod_{i=1}^{n} \mathbb{I}\{X_i \ge \theta\} e^{-(X_i - \theta)} = \underbrace{\mathbb{I}\{X_{(1)} \ge \theta\} \cdot e^{n\theta}}_{g(X_{(1)}, \theta)} \cdot \underbrace{e^{-\sum_{i=1}^{n} X_i}}_{h(\mathbf{X})}$$

По критерию факторизации, статистика

$$T(\mathbf{X}) = X_{(1)} = \min_{i = \overline{1,n}} X_i$$

является достаточной статистикой.

2. Найдем ее распределение. Воспользуемся следующим свойством экспоненциального распределения:

$$\left. \begin{array}{c} \xi_1, \dots, \xi_n - \text{независимые} \\ \xi_i \sim \operatorname{Exp}(\lambda_i) \end{array} \right\} \qquad \Longrightarrow \qquad \xi_{(1)} = \min_{i=\overline{1,n}} \xi_i \sim \operatorname{Exp}(\lambda_1 + \dots + \lambda_n)$$

У нас $X_i = \theta + \xi_i$, где $\xi_i \sim \text{Exp}(1) - \text{i.i.d.}$. Поэтому $X_{(1)} = \theta + \xi_{(1)}$, где $\xi_{(1)} \sim \text{Exp}(n)$, поэтому

$$f_{X_{(1)}}(x) = \begin{cases} ne^{-n(x-\theta)} &, & x \ge \theta, \\ 0 &, & x < \theta. \end{cases}$$

3. Проверим полноту этой статистики. Пусть выполнено, что

$$\mathbb{E}_{\theta}[g(X_{(1)})] = \int_{\theta}^{+\infty} g(x) n e^{-n(x-\theta)} dx = 0, \quad \forall \theta \in \mathbb{R}$$

$$\int_{a}^{+\infty} g(x) e^{-nx} dx = 0, \qquad \forall \theta \in \mathbb{R}$$

Дифференцируем это равенство по θ :

$$-g(\theta)e^{-n\theta} = 0 \implies g(\theta) = 0, \quad \forall \theta \in \mathbb{R}$$

Таким образом, статистика $X_{(1)}$ является **полной достаточной статистикой**.

4. Далее, найдем какую-нибудь несмещенную оценку. Заметим, что если $\xi \sim \text{Exp}(\lambda)$, то $\mathbb{E}\xi = \frac{1}{\lambda}$. Тогда

$$\mathbb{E}_{ heta} X_1 = heta + 1 \qquad \Longrightarrow \qquad \widehat{ heta}_1 = X_1 - 1 \quad - \quad$$
 несмещенная оценка

По теореме Рао-Блеквелла-Колмогорова, оценка

$$\widehat{\theta} = \mathbb{E}_{\theta} [\widehat{\theta}_1 \mid X_{(1)}] = \mathbb{E}_{\theta} [X_1 \mid X_{(1)}] - 1$$

является оптимальной.

Вычислим данное условное матожидание.

• Функция распределения X_i :

$$F_{X_i}(x) = \mathbb{P}_{\theta}\{X_i < x\} = \max(0, 1 - e^{\theta - x})$$

• Функция распределения $X_{(1)}$:

$$F_{X_{(1)}}(t) = \mathbb{P}_{\theta}\{X_{(1)} < t\} = \max(0, 1 - e^{n(\theta - t)})$$


• Функция совместного распределения X_1 и $X_{(1)}$:

$$F_{X_1,X_{(1)}}(x,t) = \mathbb{P}_{\theta}\{X_1 < x, X_{(1)} < t\} = \mathbb{P}_{\theta}\{X_1 < x\} - \mathbb{P}_{\theta}\{X_1 < x, X_{(1)} \ge t\} = \mathbb{P}_{\theta}\{X_1 < x\} - \mathbb{P}_{\theta}\{t \le X_1 < x\} \cdot \mathbb{P}_{\theta}\{X_2 \ge t\} \cdots \mathbb{P}_{\theta}\{X_n \ge t\}$$

Легко видеть, что при $x \leq \theta$ или $t \leq \theta$ эта вероятность равна 0. В остальных случаях легко вычислить:

$$F_{X_1,X_{(1)}}(x,t) = \begin{cases} 1 - e^{n(\theta-t)} - e^{\theta-x} \left(1 - e^{(n-1)(\theta-t)}\right) &, & \theta < t < x, \\ 1 - e^{\theta-x} &, & \theta < x \leq t, \\ 0 &, & x \leq \theta \text{ или } t \leq \theta. \end{cases}$$

Вот так ведет себя эта функция при фиксированном $t > \theta$.



Важно, что эта функция непрерывна, хотя ее частная производная по x разрывна в точках x=0 и x=t.

• Функция условного распределения:

$$F_{X_1 \mid X_{(1)}}(x \mid t) = \mathbb{P}_{\theta} \{ X_1 < x \mid X_{(1)} = t \}$$


При $t \le \theta$ она неопределена, при $x \le \theta$ и при $t \ge x$ она равна 0. При $\theta < t < x$:

$$F_{X_1 \mid X_{(1)}}(x \mid t) = \mathbb{P}_{\theta} \{ X_1 < x \mid X_{(1)} = t \} = \lim_{\Delta \to 0} \mathbb{P}_{\theta} \{ X_1 < x \mid t \le X_{(1)} \le t + \Delta \}$$

При достаточно малом $\Delta > 0$:

$$\begin{split} \mathbb{P}_{\theta} \big\{ X_1 < x \, \big| \, t \leq X_{(1)} \leq t + \Delta \big\} &= \frac{\mathbb{P}_{\theta} \big\{ X_1 < x, \, t \leq X_{(1)} \leq t + \Delta \big\}}{\mathbb{P}_{\theta} \big\{ t \leq X_{(1)} \leq t + \Delta \big\}} = \frac{F_{X_1, X_{(1)}}(x, t + \Delta) - F_{X_1, X_{(1)}}(x, t)}{F_{X_{(1)}}(t)} = \\ &= \frac{e^{n(\theta - t)} \left(1 - e^{-n\Delta} \right) - e^{\theta - x} e^{(n - 1)(\theta - t)} \left(1 - e^{-(n - 1)\Delta} \right)}{e^{n(\theta - t)} \left(1 - e^{-n\Delta} \right)} = \\ &= 1 - \frac{e^{\theta - x}}{e^{\theta - t}} \cdot \frac{1 - e^{-(n - 1)\Delta}}{1 - e^{-n\Delta}} = 1 - e^{t - x} \frac{(n - 1)\Delta + o(\Delta)}{n\Delta + o(\Delta)} = \\ &= 1 - e^{t - x} \frac{n - 1 + o(1)}{n + o(1)} \xrightarrow{\Delta \to +0} 1 - \frac{n - 1}{n} e^{t - x} \end{split}$$

При фиксированном $t > \theta$ она имеет вид:



В точке t эта функция имеет разрыв с 0 до $\frac{1}{n}$. Это соответствует тому, что

$$\mathbb{P}\{X_1 = t \,|\, X_{(1)} = t\} = \frac{1}{n}$$

Это логично, потому что все X_i независимы и одинаково непрерывно распределены, поэтому вероятность X_1 быть наименьшим значением есть $\frac{1}{n}$.

• Вычислим матожидание при фиксированном значении $X_{(1)}$:

$$m(t) = \mathbb{E}_{\theta} \left[X_1 \mid X_{(1)} = t \right] = \int_{\theta}^{+\infty} x \, dF_{X_1 \mid X_{(1)}}(x \mid t) = t \cdot \mathbb{P} \{ X_1 = t \mid X_{(1)} = t \} + \int_{t}^{+\infty} x \, F'_{X_1 \mid X_{(1)}}(x \mid t) \, dx = t \cdot \frac{1}{n} + \frac{n-1}{n} \int_{t}^{+\infty} x e^{t-x} \, dx = \frac{t}{n} + \frac{(n-1)(t+1)}{n} = t + 1 - \frac{1}{n}$$

Данную цепочку равенств можно проинтерпретировать:

$$\mathbb{E}_{\theta}[X_1 \mid X_{(1)} = t] = \frac{1}{n} \cdot t + \frac{n-1}{n} \int_{t}^{+\infty} x e^{t-x} dx$$

Здесь с вероятностью $\frac{1}{n}$ оказывается, что X_1 — минимальный элемент выборки. Соответствующее его значение равно t. С вероятностью $\frac{n-1}{n}$ оказывается, что X_1 имеет распределение $\mathrm{Exp}(1)$, смещенное на t.

• Искомое условное матожидание:

$$\mathbb{E}_{\theta}[X_1 \mid X_{(1)}] = m(X_{(1)}) = X_{(1)} + 1 - \frac{1}{n}$$

Итого, оптимальная оценка:

$$\widehat{\theta} = X_{(1)} - \frac{1}{n}$$

Важно заметить, что необязательно было проводить все эти громоздкие вычисления, а можно было воспользоваться теоремой Лемана-Шеффе:

Теорема Лемана-Шеффе: (Lehmann-Scheffé)

Пусть $T(\mathbf{X})$ — полная достаточная статистика, и функция $g(\cdot)$ такая, что

$$\mathbb{E}_{\theta} [q(T(\mathbf{X}))] = \theta, \qquad \forall \theta$$

 $\mathbb{E}_{\theta}\big[g(T(\mathbf{X}))\big] = \theta,$ Тогда $\widehat{\theta} = g(T(\mathbf{X}))$ — оптимальная оценка параметра $\theta.$

В этом случае функцию $g(t) = t - \frac{1}{n}$ легко угадать.

- (b) Данная модель является регулярной, поэтому оптимальную оценку можно искать следующим спосо-
 - 1. Построим оценку максимального правдоподобия $\widehat{\theta}^{\mathrm{OM\Pi}}$
 - 2. Проверим, является ли это эффективной оценкой.
 - 3. Если эффективная оценка существует, то она является как оценкой максимального правдоподобия, так и оптимальной оценкой.

Будем действовать по этому алгоритму.

1. Логарифм функция правдоподобия:

$$\ln L(\mathbf{X} \mid \theta) = \sum_{i=1}^{n} \ln \left(\frac{1}{2\theta} e^{-\sqrt{X_i/\theta}} \right) = -n \ln(2\theta) - \frac{1}{\sqrt{\theta}} \sum_{i=1}^{n} \sqrt{X_i}$$

$$\frac{d \ln L}{d \theta} = -\frac{n}{\theta} + \frac{1}{2\theta^{3/2}} \sum_{i=1}^n \sqrt{X_i} = 0 \qquad \Longrightarrow \qquad \widehat{\theta}^{\text{OM}\Pi} = \left(\frac{1}{2n} \sum_{i=1}^n \sqrt{X_i}\right)^2$$

2. Проверим эффективность, то есть что случайные величины $\frac{d \ln L}{d \theta}$ и $(\widehat{\theta} - \theta)$ пропорциональны.

$$\frac{d \ln L}{d\theta} = \frac{1}{2\theta^{3/2}} \left(\sum_{i=1}^{n} \sqrt{X_i} - 2n\sqrt{\theta} \right)$$

Пропорциональности нет, поэтому $\mathrm{OM\Pi}-\mathrm{неэ}$ фективная оценка. Про оптимальность ничего сказать не можем.

3. Построим достаточную статистику $T(\mathbf{X})$ с помощью критерия факторизации:

$$L(\mathbf{X} \mid \theta) = \frac{1}{(2\theta)^n} \exp\left\{-\frac{1}{\sqrt{\theta}} \sum_{i=1}^n \sqrt{X_i}\right\} \qquad \Longrightarrow \qquad T(\mathbf{X}) = \sum_{i=1}^n \sqrt{X_i}$$

Найдем распределение \sqrt{X} . При $x \geq 0$:

$$f_{\sqrt{X}}(x) = \frac{d}{dx}F_{\sqrt{X}}(x) = \frac{d}{dx}\mathbb{P}\{\sqrt{X} < x\} = \frac{d}{dx}\mathbb{P}\{X < x^2\} = \frac{d}{dx}F_X(x^2) = f_X(x^2) \cdot 2x = \frac{x}{\theta}e^{-x/\sqrt{\theta}}$$

Итого получаем, что

$$f_{\sqrt{X}}(x) = \begin{cases} \frac{x}{\theta} \cdot e^{-x/\sqrt{\theta}} &, & x \geq 0 \\ 0 &, & x < 0 \end{cases} \implies \sqrt{X_i} \sim \operatorname{Gamma}\left(2, \sqrt{\theta}\right)$$

Если $\xi \sim \text{Gamma}(k, \lambda)$, то плотность распределения

$$f_{\xi}(x) = \frac{x^{k-1}}{\Gamma(k)\lambda^k} \cdot e^{-x/\lambda}, \qquad x \ge 0$$

Воспользуемся свойством аддитивности гамма-распределения: если $\xi_i \sim \Gamma(k_i,\lambda)$ — независимые, то

$$\xi_1 + \ldots + \xi_n \sim \Gamma\left(\sum_{i=1}^n k_i, \lambda\right)$$

Таким образом, достаточная статистика имеет распределение

$$T(\mathbf{X}) = \sum_{i=1}^{n} \sqrt{X_i} \sim \text{Gamma}(2n, \sqrt{\theta}), \qquad f_T(x) = \begin{cases} \frac{x^{2n-1}}{(2n-1)! \, \theta^n} \cdot e^{-x/\sqrt{\theta}} &, & x \ge 0\\ 0 &, & x < 0 \end{cases}$$

4. Проверяем полноту этой статистики. Пусть для $\forall \theta > 0$:

$$\mathbb{E}_{\theta}\left[g(T(\mathbf{X}))\right] = \int_{0}^{+\infty} g(x) \frac{x^{2n-1}}{(2n-1)! \theta^n} \cdot e^{-x/\sqrt{\theta}} dx = 0$$

Обозначим $y = \frac{1}{\sqrt{\theta}} > 0$. Тогда получаем, что

$$\int_{0}^{+\infty} g(x) x^{2n-1} e^{-yx} dx = 0, \quad \forall y > 0$$

Заметим, что слева написано преобразование Лапласа функции $f(x) = g(x)x^{2n-1}$:

$$F(y) = \mathcal{L}[f](y) \stackrel{\text{def}}{=} \int_{0}^{+\infty} f(x) e^{-yx} dx = 0, \qquad \forall y > 0$$

Из единственности преобразования Лапласа получаем, что $f(x) \equiv 0$, и, значит, $g(x) \equiv 0$. Таким образом, $T(\mathbf{X})$ — полная достаточная статистика.

5. Построим оптимальную оценку с помощью теоремы Лемана-Шеффе. Найдем такую функцию g(t), что

$$\mathbb{E}_{\theta} [g(T(\mathbf{X}))] = \theta, \qquad \forall \theta > 0$$

Известно, что матожидание распределения $\operatorname{Gamma}(k,\lambda)$ равно $k\lambda$, а дисперсия — $k\lambda^2$. Поэтому можно вычислить второй момент:

$$\mathbb{E}_{\theta}(T(\mathbf{X}))^{2} = \mathbb{V}_{\theta}T(\mathbf{X}) + (\mathbb{E}_{\theta}T(\mathbf{X}))^{2} = 2n\theta + (2n\sqrt{\theta})^{2} = 2n(1+2n)\theta$$

Мы рассматриваем именно второй момент, а не саму дисперсию, потому что искомая функция g(x) не должна зависеть от параметра θ .

Тогда в качестве функции g(x) подойдет:

$$g(x) = \frac{x^2}{2n(1+2n)}$$

Тогда оптимальная оценка параметра:

$$\widehat{\theta} = g(T(\mathbf{X})) = \frac{1}{2n(1+2n)} \left(\sum_{i=1}^{n} \sqrt{X_i}\right)^2$$

Заметим, что оптимальная оценка является несмещенной, в отличие от оценки максимального правдоподобия:

$$\widehat{\theta}^{\text{OHT.}} = \frac{1}{4n^2 + 2n} \left(\sum_{i=1}^n \sqrt{X_i} \right)^2, \qquad \widehat{\theta}^{\text{OMII}} = \frac{1}{4n^2} \left(\sum_{i=1}^n \sqrt{X_i} \right)^2$$

Тем не менее, оценка максимального правдоподобия является асимптотически оптимальной.